

Predição de aprovação de cartão de crédito com aprendizado de máquina


Como o modelo classifica clientes como bons ou maus pagadores, e o que o banco pode fazer com isso?

O desafio: maus pagadores são raros

1 em 59

clientes é mau pagador

Distribuição dos 36.457 registros da base




O acerto geral engana!

Um modelo que aprove todos os clientes "acerta" 98,3% das vezes e não identifica nenhum inadimplente.


Por isso avaliamos a capacidade do modelo de colocar os maus pagadores no topo da lista de risco.

Quatro modelos comparados; o XGBoost foi o melhor

ROC-AUC: ordenar bons e maus




PR-AUC: encontrar os maus pagadores



O XGBoost tem precisão **6 vezes maior que o acaso**, mas a separação entre bons e maus ainda é modesta.

Na prática: Corte 10% de maior risco x Acaso

Maus pagadores encontrados (28 de 124)



3,8%

de acerto entre os sinalizados. 2,2 vezes a taxa da população (1,7%).

O modelo concentra o risco, mas erra muito.

25

bons clientes entram na lista para cada mau pagador encontrado.

Teste com 7.292 clientes (124 maus pagadores); lista de 730 clientes sinalizados.

Hipótese do calote

Para saber se compensa recusar, é preciso comparar o que se evita com o que se perde:

- Cada mau pagador recusado **evita um prejuízo**, que assumimos, de forma ilustrativa, ser **10 vezes** o lucro obtido com um bom cliente;
- Cada bom cliente recusado por engano **custa o lucro desse cliente** (1 unidade).

Com esses valores, o ponto de equilíbrio é uma precisão de **9,1%**: só vale recusar se, entre os sinalizados, mais de 9 em cada 100 forem maus pagadores.

Abaixo do equilíbrio

4 maus em cada 100

Prejuízo evitado: $4 \times 10 = 40$

Lucro perdido com bons clientes:

$$96 \times 1 = 96$$

Saldo: -56 (40-96)

No equilíbrio

9 maus em cada 100

Prejuízo evitado: $9 \times 10 = 90$

Lucro perdido com bons clientes:

$$91 \times 1 = 91$$

Saldo: ≈ 0

Acima do equilíbrio

15 maus em cada 100

Prejuízo evitado: $15 \times 10 = 150$

Lucro perdido com bons clientes:

$$85 \times 1 = 85$$


Saldo: +65 (150-85)

Equilíbrio = $1 \div (1 + 10) = 9,1\%$.

Exemplo com 100 clientes recusados.

Resultado: Recusar crédito com base no modelo não compensa

Nenhuma das faixas de risco compensa se a ação for recusar o crédito.



Filas maiores encontram mais maus pagadores, mas nenhuma atinge o ponto de equilíbrio, e o saldo (por 1.000 clientes) piora.

Simulação do modelo: Teste com 7.292 clientes; 124 maus; Um calote custa 10 vezes o lucro de um bom cliente. O custo real deve vir do banco.

Como usar: priorizar, não decidir

1. Priorizar

Em vez de recusar, o banco pode usar o modelo para decidir quais propostas passam por análise manual, quais pedem comprovação adicional de renda ou quais começam com limite menor. Essas ações **custam menos do que perder o cliente**, então um erro com um bom cliente sai mais barato.

2. Criar Faixas de Risco

Em vez de "aprovar/negar", usar três degraus: **Risco normal** segue o fluxo atual; **elevado** recebe cautela leve; **muito alto**, só o topo da lista, recebe ação mais forte.

3. Piloto em paralelo

Rodar por alguns meses sem alterar decisões, medir quantos sinalizados viram inadimplentes e só então ativar as ações.

Estado civil é a variável de maior peso: validar com Jurídico e Compliance antes de usá-la em decisão de crédito.

Cautelas e próximos passos

Limitações

- Poucos casos: 124 maus pagadores no teste, então os números têm margem de erro grande.
- Só dados cadastrais, sem histórico de pagamento.
- Teste sem horizonte de tempo: o desempenho pode mudar em produção.

Próximos passos

- Incluir dados de bureau e histórico de pagamento.
- Definir o custo real do calote para calibrar o corte.
- Testar o modelo sem estado civil e sem idade.
- Executar o piloto em paralelo.